Sinais do treino alinhados no mesmo eixo de passos (orçamento: 3000 passos, lote 128)

perda
(linha: treino, média de K passos;
pontos: validação)

melhor: muon η=0.003 (AdamW 0.0003), cosseno
baseline: adam η=0.001, constante
melhor sem Muon: adamw η=0.0003, wsd
instável: muon η=0.03 (AdamW 0.0003), warmup_cosseno

$\|\nabla\theta\,\mathcal{L}\|_2$ (antes do clipping)

$\|\theta\|_2$

η_t
(pontilhado: parte AdamW do Muon)

$\|\Delta\theta\|/\|\theta\|$
camada do meio

passo

Sinais por camada (primeira, do meio, última)

melhor
muon η=0.003 (AdamW 0.0003), cosseno

baseline
adam η=0.001, constante

melhor sem Muon
adamw η=0.0003, wsd

instável
muon η=0.03 (AdamW 0.0003), warmup_cosseno

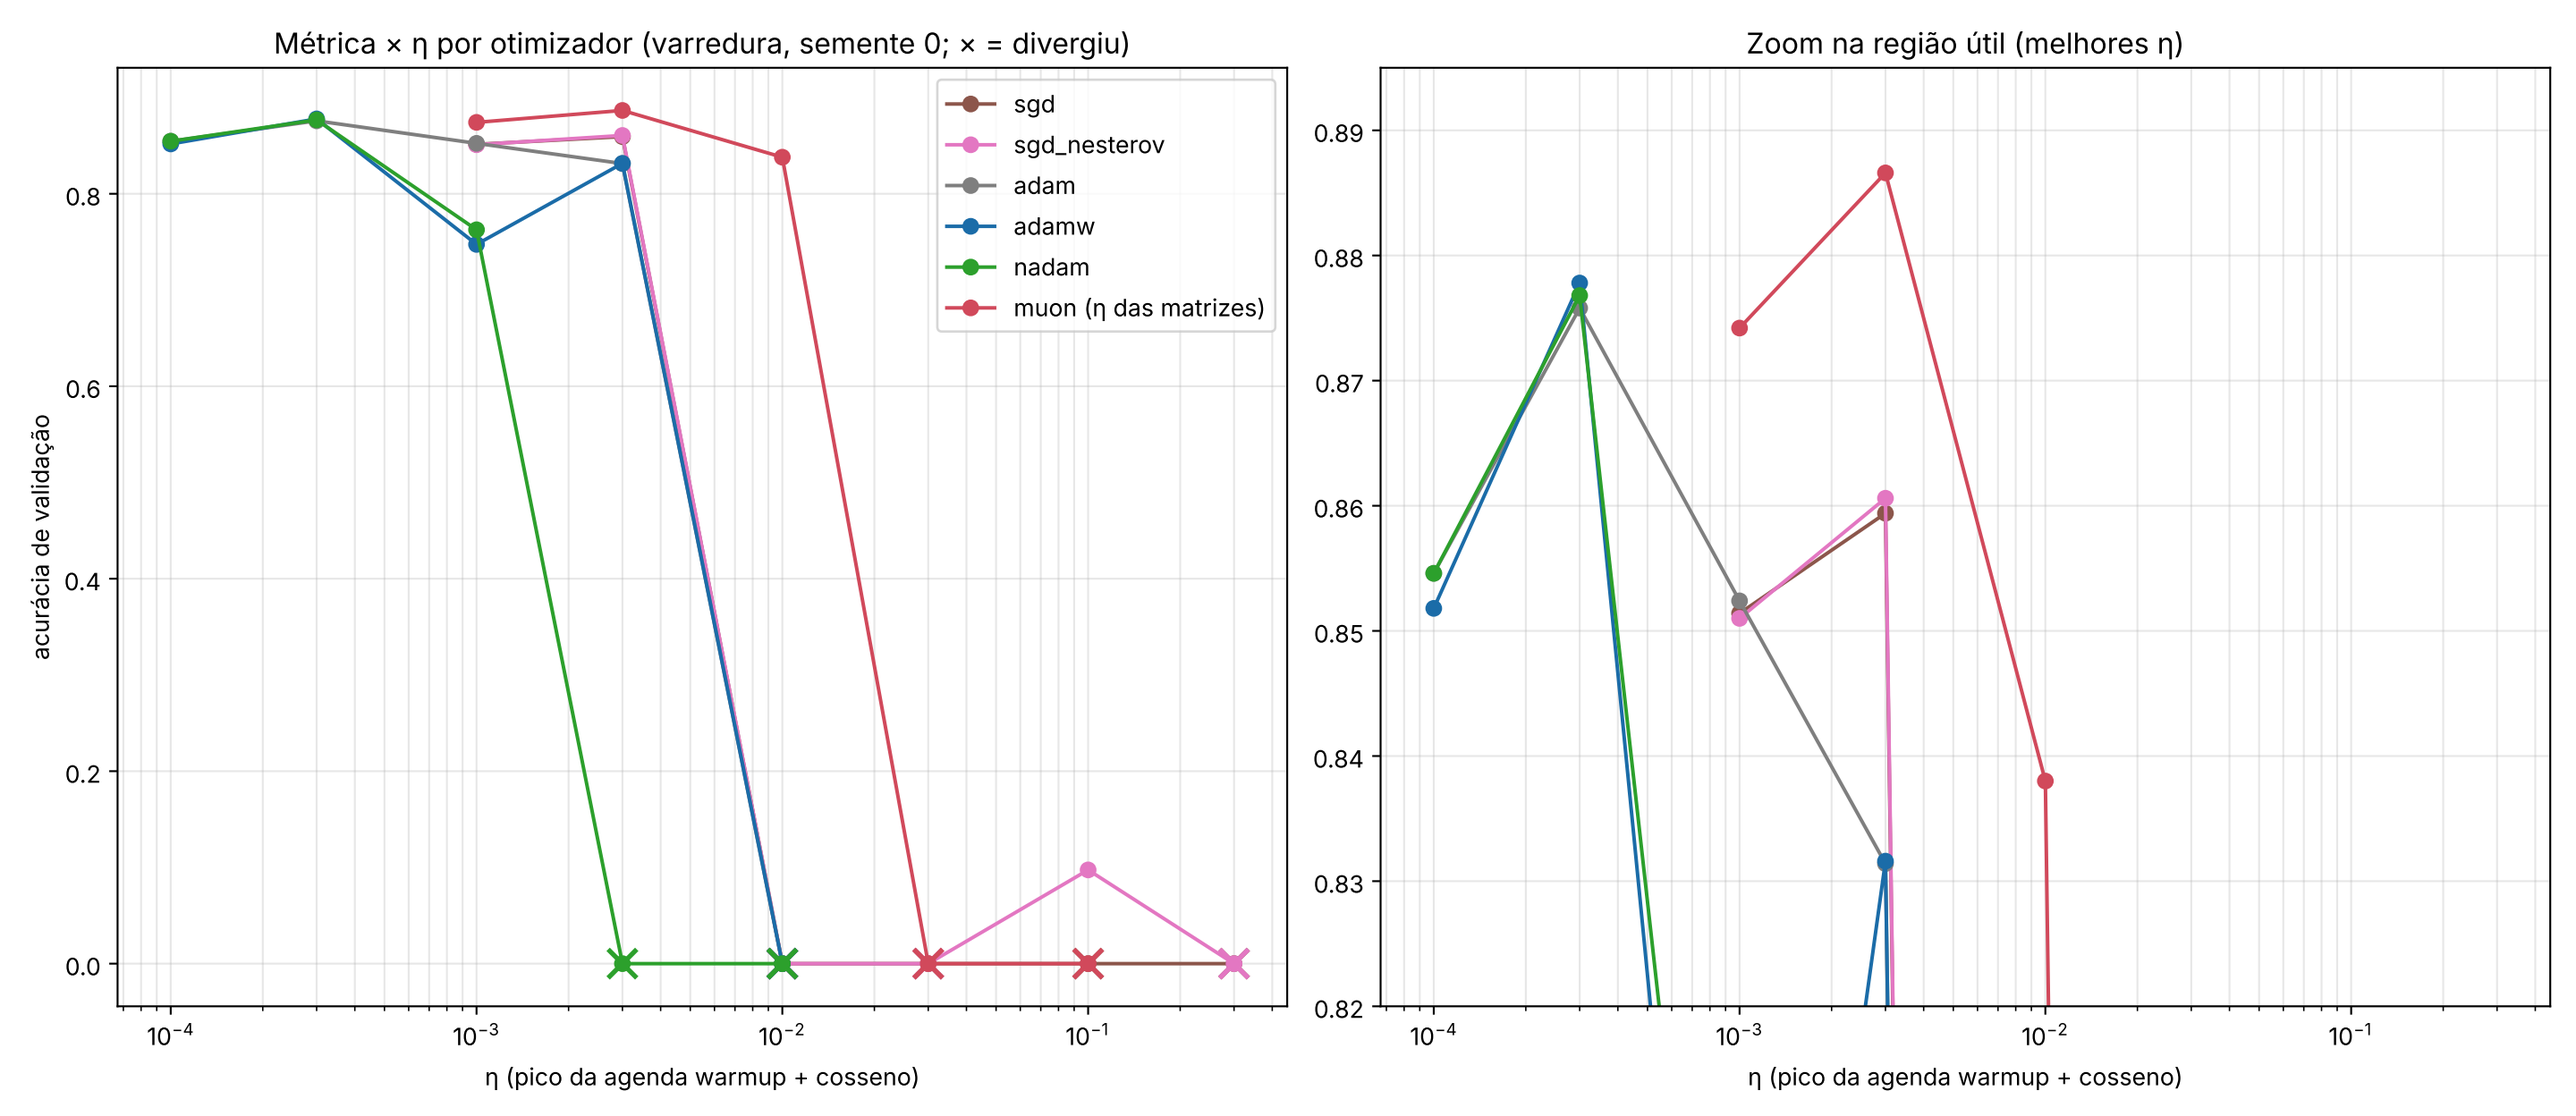
primeira
meio
última (saída)

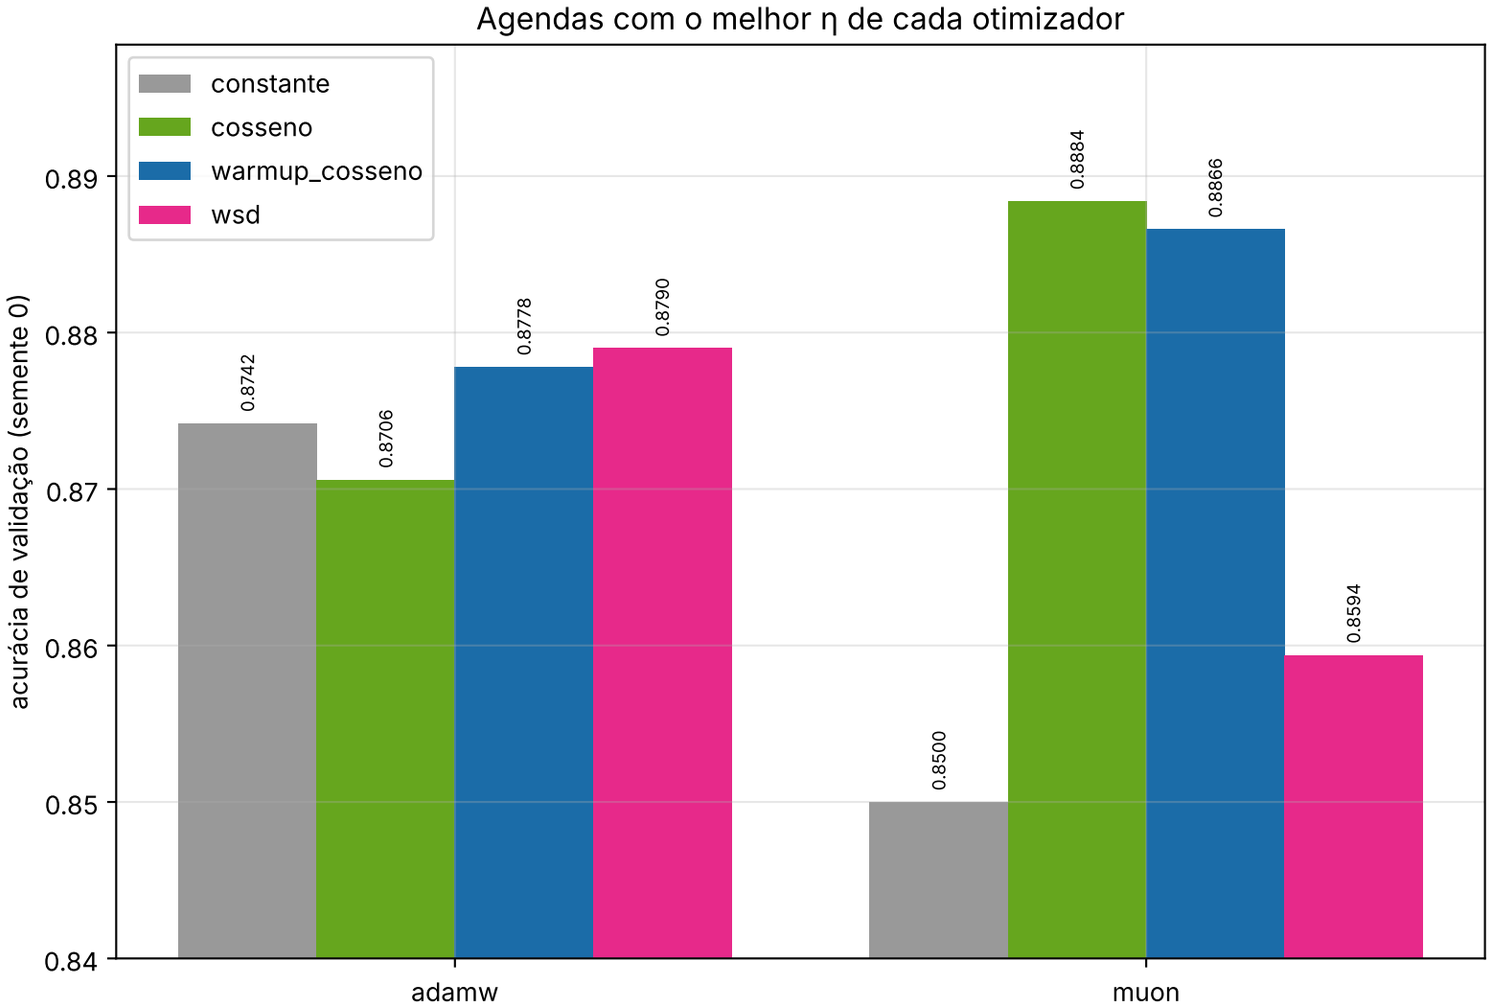
‖g‖ da camada

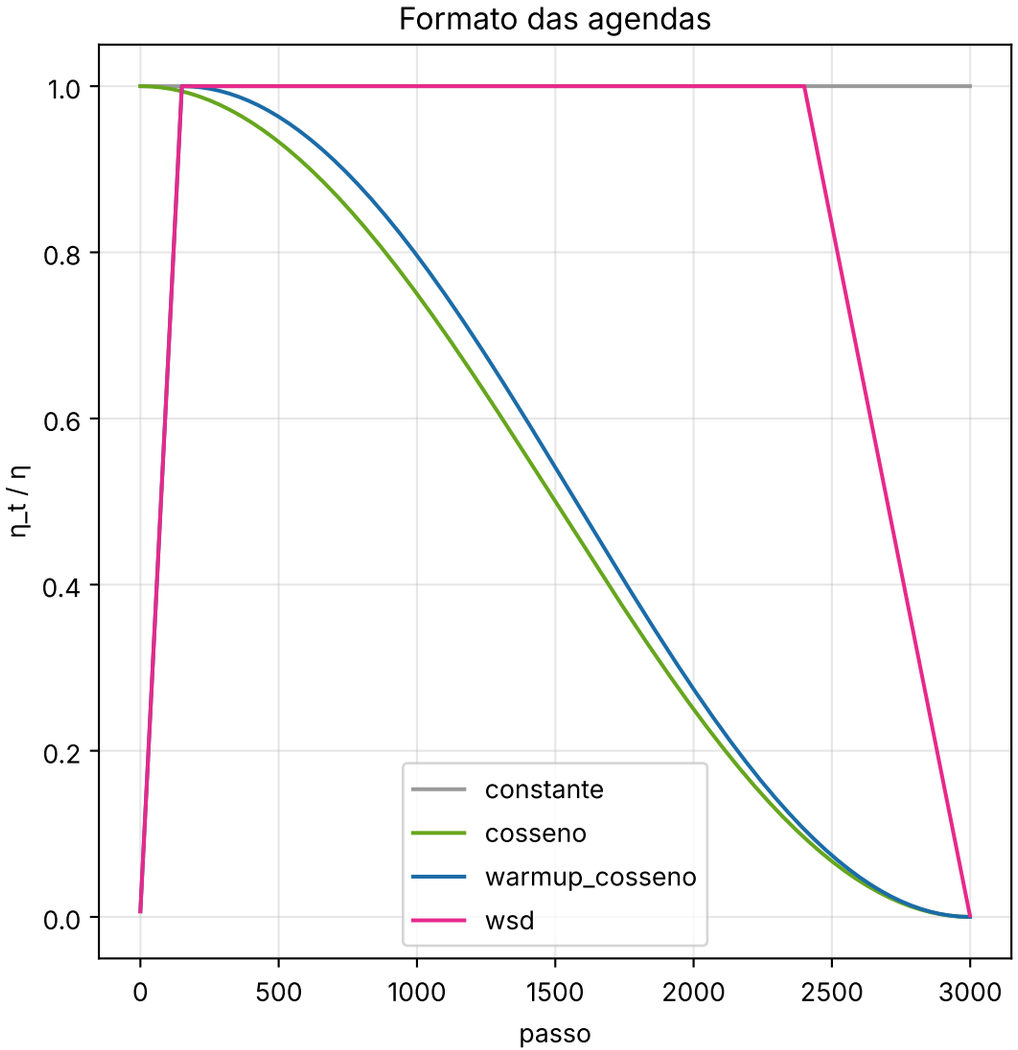
‖θ‖ da camada

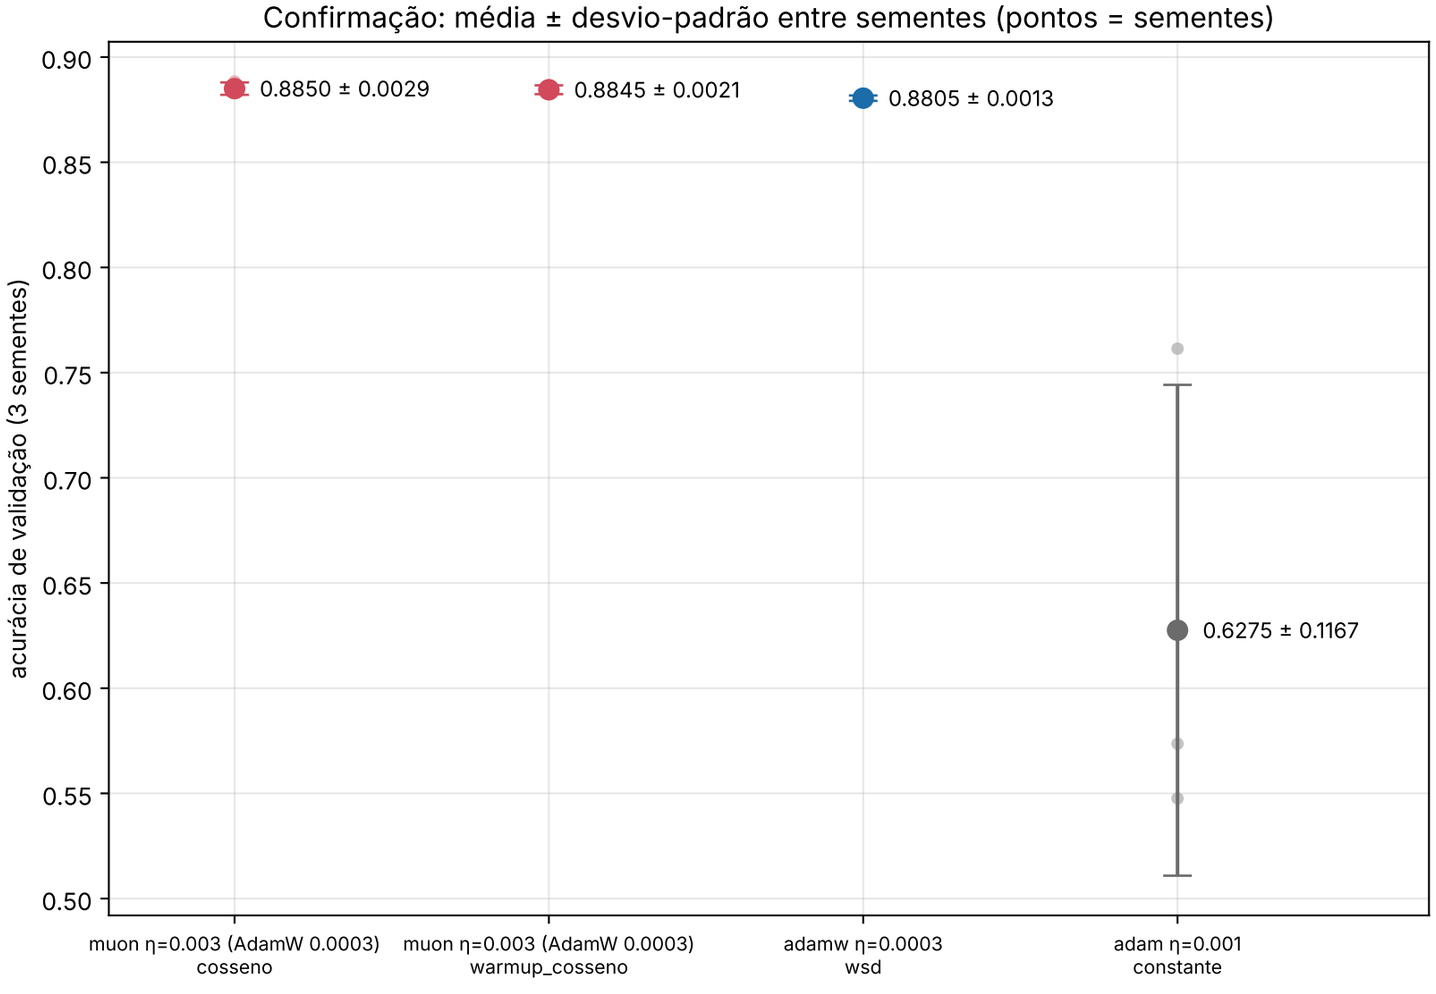
razão de atualização
‖Δθ‖/‖θ‖ (ref. 1e-3)

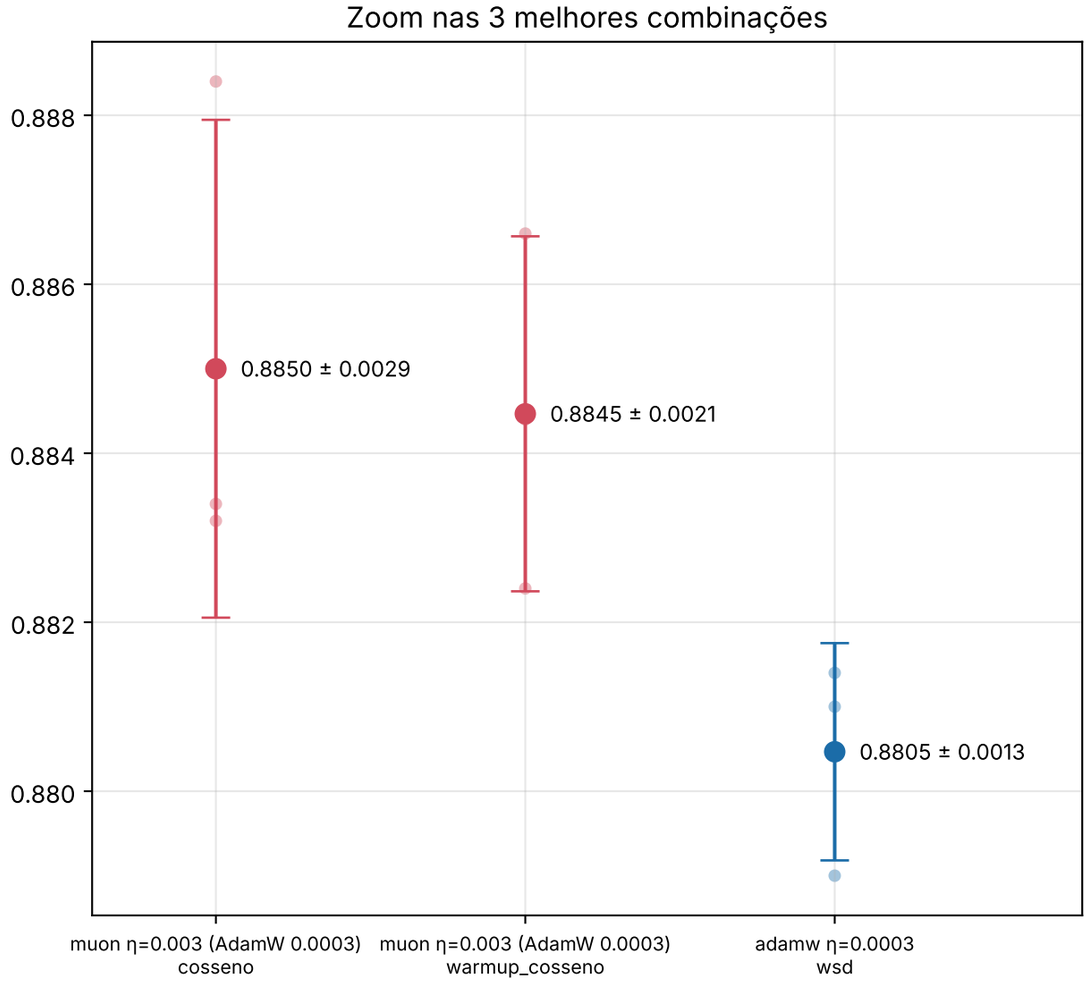
passo


Métrica × η por otimizador (varredura, semente 0; × = divergiu)
Zoom na região útil (melhores η)
acurácia de validação
η (pico da agenda warmup + cosseno)
η (pico da agenda warmup + cosseno)
sgd
sgd_nesterov
adam
adamw
nadam
muon (η das matrizes)
0.0
0.2
0.4
0.6
0.8
0.82
0.83
0.84
0.85
0.86
0.87
0.88
0.89
10^{-4}
10^{-3}
10^{-2}
10^{-1}


Agendas com o melhor η de cada otimizador
constante
cosseno
warmup_cosseno
wsd
acurácia de validação (semente 0)
0.89
0.88
0.87
0.86
0.85
0.84
0.8742
0.8706
0.8778
0.8790
0.8500
0.8884
0.8866
0.8594
adamw
muon


Formato das agendas
1.0
0.8
0.6
0.4
0.2
0.0
η_t / η
constante
cosseno
warmup_cosseno
wsd
0
500
1000
1500
2000
2500
3000
passo


Confirmação: média ± desvio-padrão entre sementes (pontos = sementes)
acurácia de validação (3 sementes)
0.90
0.85
0.80
0.75
0.70
0.65
0.60
0.55
0.50
0.8850 ± 0.0029
0.8845 ± 0.0021
0.8805 ± 0.0013
0.6275 ± 0.1167
muon η=0.003 (AdamW 0.0003)
cosseno
muon η=0.003 (AdamW 0.0003)
warmup_cosseno
adamw η=0.0003
wsd
adam η=0.001
constante


Zoom nas 3 melhores combinações
0.888
0.886
0.884
0.882
0.880
0.8850 ± 0.0029
0.8845 ± 0.0021
0.8805 ± 0.0013
muon η=0.003 (AdamW 0.0003)
cosseno
muon η=0.003 (AdamW 0.0003)
warmup_cosseno
adamw η=0.0003
wsd