Desafio 3 — o melhor treino para a rede de 48 camadas do Desafio 2

Fashion-MNIST • MLP 784→128×46→10, LeakyReLU + init Monte Carlo, sem normalização • 3000 passos, lote 128 para todos

Receita vencedora: muon η=0.003 (AdamW 0.0003), cosseno

Validação (3 sementes): 0.8850 ± 0.0029 vs baseline Adam η=1e-3 constante: 0.6275 ± 0.1167
Ganho pareado por semente: +0.2575 ± 0.1137
Teste (usado uma vez): 0.8791 ± 0.0004 vs 0.6273 ± 0.1102
Melhor sem Muon (AdamW η=3e-4 + WSD): 0.8805 ± 0.0013 — Muon vence nas 3 sementes, +0.0045 ± 0.0042 (margem ≈ desvio)

Diagnóstico lido nos sinais

- Baseline (Adam, η=1e-3 constante): razão de atualização ≈2×10^{-3} na 1ª e na última camada (acima da referência 10^{-3}), picos de ‖g‖ (até 100) seguidos de saltos na perda (validação cai a 25% no passo 1200 e a 10% no 2800) e ‖θ‖ da 1ª camada crescendo sem estabilizar (15,9→21,4): passo grande demais e sem decaimento — o resultado final depende de onde o treino parou (0,55 a 0,76 entre sementes).
- η ajustada + cosseno: η_t→0 no fim e a perda "assenta" no vale; o desvio entre sementes cai de 0,117 para 0,003.
- Por que Muon: o passo ortogonalizado faz a camada do meio mudar ~$6{,}6\times10^{-4}$ por passo, mesmo com ‖g‖ 16× menor que o da 1ª camada; no AdamW ela anda 3×10^{-4} (metade). Perda de treino 0,19 vs 0,29 → +0,45 p.p. de validação, vencendo nas 3 sementes.
- Limite: com η=0,03 o Muon diverge (‖θ‖ 109→200, ‖g‖×200, razão ~10^{-2}).

